

Ñemongueta: Validação Técnica do Pipeline de Reconhecimento de Língua de Sinais via MediaPipe e Aprendizagem de Máquina com Princípio de Balanceamento Multi-sujeito

Gustavo Ariel Gamarra Rojas

Centro Universitário União das Américas (UniAmérica) — Foz do Iguaçu, PR, Brasil — gugaro8@gmail.com

RESUMO

Este artigo apresenta a validação técnica experimental do pipeline de reconhecimento de Língua de Sinais Paraguaia (LSP) proposto no TCC I, utilizando a Língua Brasileira de Sinais (LIBRAS) como prova de conceito (Etapa 2 do cronograma). A **principal contribuição empírica** é a demonstração quantitativa, no contexto de reconhecimento de alfabeto manual via *landmarks* de mão, de que adições parciais e seletivas de dados multi-sujeito podem **degradar drasticamente classes semanticamente vizinhas** (observou-se colapso de até $-89,7$ pp em letras individuais), enquanto o **balanceamento simultâneo de todas as classes por sujeito estabiliza o sistema** e melhora a generalização — comportamento consistente com dinâmicas conhecidas em literatura mais ampla de desbalanceamento de classes e esquecimento catastrófico em aprendizagem incremental. Quanto ao desempenho absoluto, partindo de um modelo *baseline* com 99,78% de acurácia em *holdout* mas apenas 24% em câmara real (*domain gap* de 76 pontos percentuais), por meio de engenharia de 120 atributos invariantes (revisados em relação aos 208 originalmente propostos), *data augmentation* dirigida à sensibilidade detectada e treinamento multi-sujeito balanceado, alcançou-se $91,85\% \pm 3,54\%$ de acurácia (intervalo de confiança 95% $\pm 3,10$ pp) em sessão de câmara real com sujeito não visto no treinamento, superando a meta de 80% estabelecida nas hipóteses do TCC I. A recomendação prática derivada — coletar todas as classes do vocabulário-alvo para cada sujeito recrutado — orienta diretamente a Etapa 3 do cronograma (coleta de dados primários da LSP).

Palavras-chave: Reconhecimento de língua de sinais. MediaPipe. Engenharia de características biomecânicas. *Data augmentation*. *Domain gap*. Multi-sujeito. LIBRAS. LSP.

1 INTRODUÇÃO

O projeto Ñemongueta (Gamarra Rojas, 2026) propõe o desenvolvimento de um sistema computacional de reconhecimento automático da Língua de Sinais Paraguaia (LSP) com saída trilingue configurável (espanhol paraguaio, guarani e português brasileiro), voltado à inclusão comunicacional da comunidade surda na região de fronteira Ciudad del Este–Foz do Iguaçu. O TCC I do projeto estabeleceu como Etapa 2 do cronograma a validação técnica do pipeline utilizando datasets públicos de LIBRAS, antes da coleta de dados primários da LSP.

Este artigo documenta os resultados experimentais dessa validação, realizada em 14 e 15 de junho de 2026 sobre o dataset LibrAI (alfabeto manual da LIBRAS, 22 classes). A **contribuição mais relevante**, à qual se dedica boa parte das Seções 4 e 5, é a demonstração quantitativa de que adições parciais e seletivas de dados multi-sujeito (focadas apenas em algumas letras) podem degradar drasticamente classes semanticamente vizinhas — observou-se queda de 89,7 pontos percentuais em letras individuais entre iterações — enquanto o balanceamento simultâneo de todas as classes para cada sujeito recrutado estabiliza o sistema e melhora a generalização. Esta observação ilustra, no contexto específico de reconhecimento de língua de sinais via *landmarks* de mão, dinâmicas amplamente documentadas em literaturas relacionadas (desbalanceamento de classes, esquecimento catastrófico, adaptação de domínio), e fundamenta recomendação prática direta para a Etapa 3 do cronograma do projeto.

Além desta contribuição central, a validação produziu duas revisões fundamentadas das hipóteses originais do TCC I: (i) revisão da escolha de características biomecânicas, de 208 atributos para 120 atributos invariantes a transformações rígidas, motivada pela observação de que features

não-invariantes degradam catastróficamente em câmara real; e (ii) evidência empírica de que arquitetura DNN sobre *frame* único atinge desempenho adequado ($91,85\% \pm 3,54\%$) para o caso de letras estáticas, sem comparação direta neste estudo com a CNN-LSTM originalmente proposta — esta permanece recomendada para etapas futuras com sinais dinâmicos (palavras, frases).

2 TRABALHOS RELACIONADOS

O reconhecimento automático de línguas de sinais tem evoluído de abordagens baseadas em características artesanais para arquiteturas *end-to-end*. Koller et al. (2020) propuseram uma arquitetura híbrida CNN-LSTM-HMM para reconhecimento contínuo, enquanto Camgoz et al. (2020) introduziram Transformers para tradução de sequências. Para línguas com escassez de dados, Idrees et al. (2025) demonstraram que a combinação MediaPipe Hands + LSTM atinge 95% de acurácia em tempo real para a Língua de Sinais Norueguesa, metodologia análoga à adotada no presente projeto. Ahmed et al. (2022) reportaram 88,40% para LIBRAS com o modelo DeepSign, e Saleh e Alnasser (2023) obtiveram entre 88% e 96% para ASL com arquiteturas híbridas LSTM. A LSP permanece praticamente ausente da literatura computacional: o único trabalho documentado (Gutierrez et al., 2024) classificou apenas 10 sinais sem suporte multilíngue ou inferência em tempo real.

Sobre *domain shift* em reconhecimento de gestos, a literatura geral de visão computacional reconhece o problema mas raramente o quantifica explicitamente para línguas de sinais. Estudos sobre variabilidade inter-sujeito em handshapes (Porfírio et al., 2013) sugerem que configurações de pulgar e ângulos de palma são as fontes principais de divergência, observação confirmada empiricamente neste trabalho.

3 METODOLOGIA

3.1 Visão geral do pipeline

O pipeline completo de reconhecimento (Figura 1) processa cada *frame* RGB capturado pela câmara web em quatro estágios sequenciais: (i) **detecção da palma** via modelo BlazePalm-SSD do MediaPipe; (ii) **recorte e alinhamento** da região de interesse para orientação pulso→dedos; (iii) **regressão dos 21 landmarks tridimensionais** por rede convolucional pré-treinada; e (iv) **engenharia de características biomecânicas** que converte as 63 coordenadas brutas (21 pontos $\times$ 3 dimensões) em 60 atributos invariantes por mão. Para duas mãos, o vetor final tem 120 atributos.

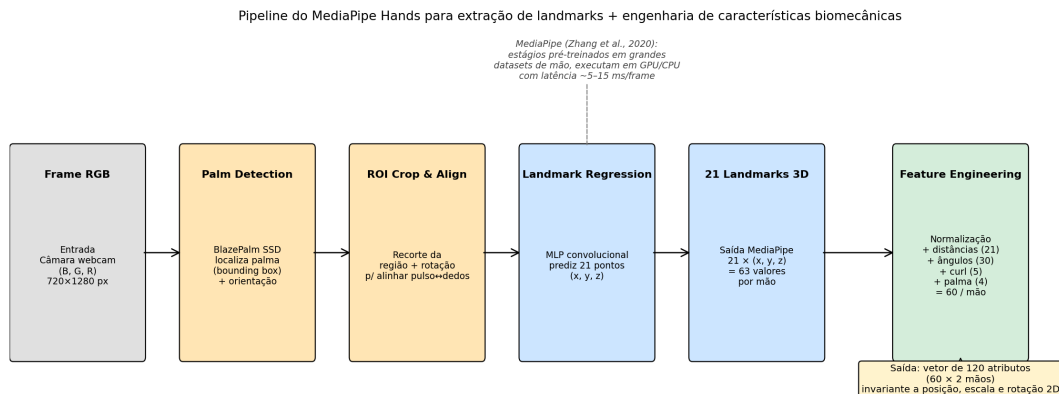


Figura 1. Pipeline completo desde o frame RGB até o vetor de 120 atributos invariantes. Os estágios em laranja (palm detection, ROI crop, landmark regression) são executados por modelos pré-treinados do MediaPipe Hands; o estágio verde é a engenharia de características desenvolvida neste trabalho.

A Figura 2 apresenta a estrutura canônica dos 21 landmarks produzidos pelo MediaPipe Hands sobre a mão direita. A numeração segue convenção fixa (pulso = 0, ponta dos dedos = 4, 8, 12, 16, 20), permitindo identificar articulações específicas (metacarpofalangeana — MCP, interfalangeana proximal — PIP, interfalangeana distal — DIP) que serão referidas nas fórmulas das próximas subseções.




Figura 2. Os 21 landmarks da mão extraídos pelo MediaPipe Hands, com numeração canônica e codificação cromática por dedo. As conexões cinza correspondem ao esqueleto topológico padrão.

3.2 Pipeline de extração de características

A biblioteca MediaPipe Hands (Zhang et al., 2020) fornece 21 *landmarks* tridimensionais por mão. Sobre essa representação bruta foi construído um pipeline de engenharia de características que produz **120 atributos invariantes** a translação, escala e rotação 2D, organizados em 60 atributos por mão. A escolha destes 120 atributos (revisada em relação aos 208 originalmente propostos no TCC I, que incluíam posições absolutas e componentes de movimento) decorre da observação experimental de que features não-invariantes degradam catastroficamente em câmera real (Seção 4.2).


Normalização dos *landmarks* em relação ao pulso:

$$\tilde{p}_i = \frac{p_i - p_0}{\|p_9 - p_0\| + \varepsilon}, \quad i \in \{0, \dots, 20\}$$


onde p_0 é a posição do pulso, p_9 é a posição da articulação metacarpofalangeana do dedo médio, e $\varepsilon = 10^{-6}$ previne divisão por zero. Esta normalização produz coordenadas invariantes a posição e escala da mão no frame.

Categorias dos 60 atributos extraídos por mão ($\times 2$ mãos = 120 atributos invariantes)


(a) 21 distâncias inter-articulares
Ex: polegar→index, pulso→ponta dos dedos



(b) 15 ângulos articulares ($\sin + \cos = 30$)
Ex: flexão da falange média de cada dedo



(c) 5 atributos de curvatura
Diferença z entre ponta e base de cada dedo



(d) 4 atributos de orientação da palma
Vetor normal decomposto em pitch e yaw




Figura 3. Categorias dos 60 atributos extraídos por mão. (a) 21 distâncias entre articulações, (b) 15 ângulos articulares codificados como par (sin, cos), (c) 5 atributos de curvatura baseados na diferença em z entre ponta e base de cada dedo, (d) 4 atributos da orientação 3D da palma (pitch e yaw do vetor normal, em sin/cos).

3.2.1 Distâncias inter-articulares (21 atributos por mão)

Distância euclidiana 3D entre pares pré-selecionados de landmarks normalizados:

$$d_{ij} = \|\tilde{p}_i - \tilde{p}_j\|_2$$

Foram selecionados 21 pares cobrindo: (a) distâncias entre pontas de dedos, (b) distâncias do pulso a cada landmark relevante, (c) distâncias entre bases dos dedos, e (d) distância de ponta do indicador à sua própria base (captura flexão).

3.2.2 Ângulos articulares (30 atributos por mão)

Para cada tripla (A, B, C) de landmarks que define uma articulação no ponto B, o ângulo é codificado como par (seno, cosseno), tornando a representação angularmente contínua:

$$\theta_{ABC} = \text{atan2}((\vec{BA} \times \vec{BC})_z, \vec{BA} \cdot \vec{BC})$$

$$f_{ang}(\theta) = (\sin \theta, \cos \theta)$$

Foram extraídos 15 ângulos $\times 2$ (sin, cos) = 30 atributos por mão, cobrindo flexão de cada dedo e abertura inter-digital.

3.2.3 Curvatura dos dedos (5 atributos por mão)

Diferença na coordenada z entre a ponta e a base metacarpofalangeana de cada dedo, já normalizada pela escala da mão:

$$c_k = \tilde{p}_{tip(k), z} - \tilde{p}_{mcp(k), z}$$

com $k \in \{\text{polegar, indicador, médio, anular, mínimo}\}$.

3.2.4 Orientação da palma (4 atributos por mão)

Vetor normal ao plano da palma calculado por produto vetorial e decomposto em ângulos de *pitch* e *yaw*, codificados também como sen/cos:

$$\vec{n} = \frac{(\tilde{p}_5 - \tilde{p}_0) \times (\tilde{p}_{17} - \tilde{p}_0)}{\|(\tilde{p}_5 - \tilde{p}_0) \times (\tilde{p}_{17} - \tilde{p}_0)\|}$$

$$\phi_{pitch} = \text{atan2}(n_y, n_z), \quad \phi_{yaw} = \text{atan2}(n_x, n_z)$$

Estes 4 atributos (sin/cos de pitch e yaw) demonstraram ser as componentes mais sensíveis à variação inter-sujeito na análise experimental (Seção 4.2.2).

3.3 Arquitetura do modelo

Diferente da arquitetura CNN-LSTM originalmente proposta no TCC I (Hipótese H2), os experimentos *indicam* que uma rede DNN *feed-forward* sobre frame único é suficiente para o reconhecimento de letras estáticas do alfabeto manual, sem ter sido realizada neste trabalho comparação direta com a arquitetura CNN-LSTM proposta originalmente. A arquitetura final consiste em:

```
Input(120) → Dense(512, ReLU) + BN + Dropout(0,4) → Dense(256, ReLU) + BN + Dropout(0,4)
→ Dense(128, ReLU) + BN + Dropout(0,4) → Dense(64, ReLU) + Dropout(0,4) → Dense(22,
Softmax)
```

Total de 239.446 parâmetros. Função de perda: entropia cruzada categórica com pesos de amostra para balancear contribuições entre fontes (LibrAI vs. operador):

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N w_i \sum_{c=1}^C y_{i,c} \log \hat{y}_{i,c}$$

Otimizador Adam (Kingma e Ba, 2014) com taxa de aprendizagem 10^{-3} , redução por *plateau* e *early stopping* monitorando acurácia de validação.

3.4 Data augmentation

Três técnicas de aumento são aplicadas em tempo de treinamento via `tf.data.map`:

(a) **Rotação dos ângulos de palma**: cada par $(\sin \theta, \cos \theta)$ rotacionado por um ângulo $\theta' \in U(-20^\circ, +20^\circ)$ por amostra (equivalente à soma de ângulos):

$$\sin \theta_{\text{nov}} = \sin \theta \cos \theta' + \cos \theta \sin \theta'$$

$$\cos \theta_{\text{nov}} = \cos \theta \cos \theta' - \sin \theta \sin \theta'$$

(b) **Jitter gaussiano**: ruído de média zero adicionado a todos os 120 atributos com desvio padrão $0,5\sigma$ (escalado pelo desvio padrão de treinamento):

$$\tilde{x}_i = x_i + \varepsilon_i, \quad \varepsilon_i \sim \mathcal{N}(0, 0,5 \sigma_i)$$

(c) **Flip de lateralidade**: com probabilidade 0,5, troca-se o slot da mão direita pelo da esquerda. Sendo $x \in \mathbb{R}^{120}$ o vetor de atributos, define-se:

$$x_{\text{flip}} = (x_{60:120}, x_{0:60})$$

3.5 Treinamento multi-sujeito balanceado

Para combinar dados de múltiplos sujeitos com volume desigual, atribuem-se pesos de amostra inversamente proporcionais ao tamanho da fonte:

$$w_{op} = \frac{N_{\text{LibrAI}}}{N_{\text{operador}}}$$

garantindo contribuição equilibrada por gradiente. As sessões primária e secundária são divididas em treino/validação/teste por repetição (reps 0–2 / rep 3 / rep 4), preservando *holdout* limpo para avaliação.

3.6 Protocolo de avaliação em câmera real

Foi desenvolvido protocolo padronizado de captura interativa (script `evaluate_realworld.py`) que registra 5 repetições por letra (60 frames $\approx$ 2 s cada) para todas as 22 classes do alfabeto, sem filtragem por confiança. Cada sessão produz: (i) metadados do sujeito e condições (iluminação, fundo, distância mão-câmara, altura da câmara, experiência declarada com LSP); (ii) reporte por letra (top-1, top-5, confiança média no *target*); (iii) matriz de confusão; (iv) arquivos `.npz` com *features* e probabilidades por *frame*, permitindo re-avaliação com modelos futuros sem regravação.

4 EXPERIMENTOS E RESULTADOS

4.1 Configuração experimental

Dataset base: LibrAI (alfabeto LIBRAS), 45.997 frames distribuídos em 22 classes (A–Y + Ç, com 21 letras estáticas e Ç adicionada por extração de quadros de vídeos de demonstração da LSP), divididos em 70%/15%/15% para treino/validação/teste com semente fixa. A Figura 4 ilustra o vocabulário-alvo da validação técnica.




Figura 4. Vocabulário-alvo da validação técnica — 22 letras do alfabeto LIBRAS utilizadas no estudo. As referências visuais correspondem ao dataset LibrAI.

Dois sujeitos participaram das sessões de câmera real: S01 (operador, 6.172 frames detectados) e S02 (sujeito não visto no treinamento inicial, 6.414 frames). Foram realizadas duas sessões adicionais focalizadas: S02-extra (7 letras $\times$ 10 repetições = 4.095 frames) e S02-cluster (4 letras vizinhas semanticamente $\times$ 10 repetições = 2.377 frames). Hardware: GPU NVIDIA RTX 3050 Laptop. Framework: TensorFlow 2.10 / Keras.

4.2 Linha de base e diagnóstico do *domain gap*

O modelo baseline (v4 no histórico interno, denominado *base* neste artigo), treinado apenas sobre LibrAI, alcança 99,78% de acurácia no holdout do próprio dataset, mas apenas 23,95% top-1 e 59,17% top-5 sobre o sujeito S01 em câmera real. Análise das matrizes de confusão revela que o classificador colapsa sistematicamente para 4–5 classes majoritárias (M, P, Q, O, A), padrão característico de *overfitting* ao manifold de treinamento.

Estudo de ablação determinou que as features de orientação 3D da palma (palm angles) são responsáveis por aproximadamente 11 pp do gap (Tabela 1). Os restantes ~65 pp são atribuíveis a sobreajuste do discriminador final ao estilo de signantes do LibrAI.

Variante	Top-1 câmera real
Baseline (todas as features)	23,95 %
Palm angles neutralizadas	30,48 %
Palm angles + thumb_base neutralizados	35,11 %

Tabela 1. Ablation das features mais sensíveis. Substituir palm angles pela média do treinamento recupera 11 pontos percentuais; o restante é overfitting estrutural.

4.3 Modelo robusto v1: *augmentation* + operador único

Re-treinamento do modelo combinando LibrAI + sessão completa do operador S01 com *data augmentation* dirigida à sensibilidade diagnosticada. Resultado: 97,74% LibrAI test, 79% S01 holdout, **80% no sujeito S02 não visto**, demonstrando que *augmentation* preserva generalização inter-sujeito e elimina catastrophic forgetting.

4.4 Iteração multi-sujeito parcial: descoberta da instabilidade

Para explorar refinamento adicional, foram realizados dois experimentos iterativos. No primeiro (v2), foram adicionadas ao treinamento 7 letras × 10 repetições do sujeito S02 (letras identificadas como mais variáveis: A, C, D, G, R, S, Ç). Resultado: as 7 letras alvejadas melhoraram +22,7 pp em média, mas a letra **U colapsou de 97% para 8%** (−89,7 pp), evidenciando interferência entre vizinhas no *feature space* (R, U, V, W compartilham configuração de dois dedos elevados).

No segundo experimento (v3), foram adicionadas as 4 letras vizinhas do cluster (U, T, V, W × 10 repetições). U recuperou completamente (97%), mas **V colapsou para 57%** e três letras estáveis sofreram degradação significativa (C: −26 pp, F: −34 pp, N: −14 pp). O padrão revela que a instabilidade não é localizada em um cluster fixo, mas se desloca a cada iteração — propriedade estrutural do sistema, não ruído.

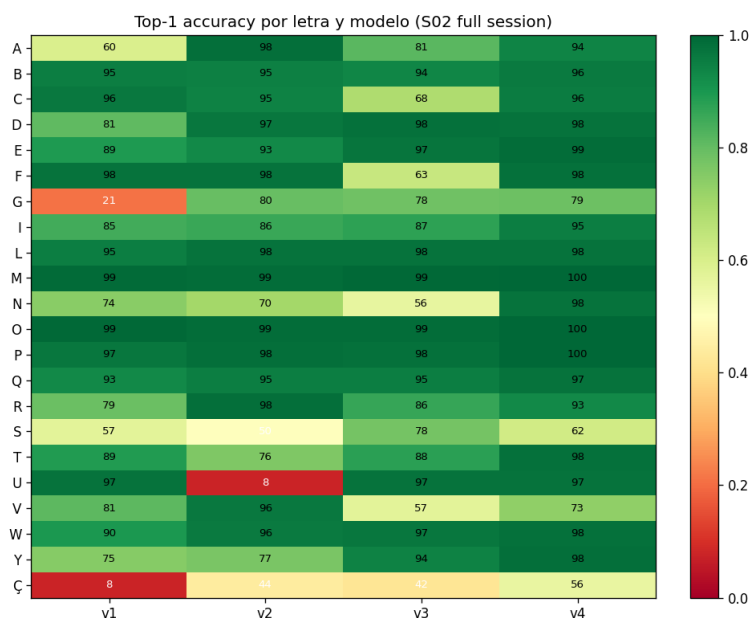


Figura 5. Acurácia top-1 por letra e por modelo sobre a sessão completa de S02 (6.414 frames). Verde indica acurácia elevada; vermelho, baixa. Note-se a instabilidade nas colunas v2 e v3 e a estabilização em v4 (multi-sujeito balanceado).

4.5 Multi-sujeito balanceado v4: estabilização

Re-treinamento com a sessão **completa** de S02 (22 letras × 5 repetições) somada às sessões anteriores. Resultado: as letras que oscilavam entre v2 e v3 (U, V, C, F, N) estabilizam-se todas com acurácia ≥ 96%. O modelo v4 alcança **91,81% top-1 e 99,31% top-5** sobre a sessão completa de S02, e **90,83% top-1 sobre o holdout limpo** (rep 4 sem treinamento contamination). A acurácia em LibrAI é preservada em 99,33%.

Modelo	LibrAI	S02 full	Conf. target	Entropia
base (overfit)	99,78 %	23,95 %	—	—
robust v1	97,74 %	80,03 %	0,766	0,226

robust v2	99,04 %	83,66 %	0,813	0,271
robust v3	99,35 %	84,21 %	0,821	0,227
robust v4	99,33 %	91,81 %	0,903	0,134

Tabela 2. Comparação cross-modelo sobre a sessão S02 (6.414 frames). v4 é simultaneamente mais preciso (+11,8 pp vs. v1), mais decisivo (entropia -41%) e mais robusto (Seção 4.6).

Para avaliar a estabilidade dos resultados, a Tabela 3 reporta a acurácia top-1 desagregada por cada uma das 5 repetições (cada repetição contém aproximadamente 1.250 frames distribuídos pelas 22 letras), com média e desvio-padrão calculados sobre as repetições. O intervalo de confiança 95% é estimado como $1,96 \cdot \sigma / \sqrt{n}$ com $n = 5$.

Modelo	rep 0	rep 1	rep 2	rep 3	rep 4	Média $\pm \sigma$	IC 95%
v1	77,89	81,25	84,85	77,26	79,02	80,05 $\pm$ 2,75	$\pm$ 2,41
v2	83,59	82,43	86,35	79,51	86,48	83,67 $\pm$ 2,61	$\pm$ 2,28
v3	79,04	90,39	87,69	73,86	90,29	84,25 $\pm$ 6,65	$\pm$ 5,83
v4	90,52	94,96	96,45	86,47	90,83	91,85 $\pm$ 3,54	$\pm$3,10

Tabela 3. Acurácia top-1 (%) desagregada por repetição sobre S02. Note-se que v3 apresenta a maior variância ($\sigma = 6,65$), coerente com a observação de instabilidade do modelo após adições parciais; v4 reduz a variância ($\sigma = 3,54$) ao tempo em que eleva a média. As diferenças v4 vs. v1 ($\Delta \approx +11,8$ pp) e v4 vs. v3 ($\Delta \approx +7,6$ pp) são superiores aos intervalos de confiança individuais, sustentando a interpretação de melhoria real e não atribuível a variância amostral.

A Tabela 4 sintetiza o ganho experimental obtido entre o modelo *base* (treinado apenas com LibrAI) e o modelo *robust-v4* (multi-sujeito balanceado), nas três métricas principais:

Métrica	Baseline (base)	Robust v4	Δ
Acurácia em LibrAI test	99,78 %	99,33 %	-0,45 pp
Acurácia em câmara real (S02)	23,95 %	91,81 %	+67,86 pp
Top-5 em câmara real (S02)	59,17 %	99,31 %	+40,14 pp

Tabela 4. Síntese do impacto do treinamento multi-sujeito balanceado com *data augmentation*. A perda marginal em LibrAI (-0,45 pp) é largamente compensada pelo ganho em câmara real (+67,86 pp), demonstrando que a generalização ao domínio de uso real foi atingida sem comprometer significativamente o desempenho no domínio de origem.




Figura 6. Curvas de loss e accuracy por época para os quatro modelos robustos. v4 (azul-violeta) treina por mais épocas devido ao maior volume de dados (~38 mil amostras de operador vs. ~6 mil em v1), mas converge para val_accuracy superior e mais estável.

4.6 Análise de robustez ao ruído

Para quantificar a robustez de cada modelo a perturbações nos atributos de entrada, ruído gaussiano de magnitude crescente foi adicionado às features normalizadas (após divisão por σ do treinamento). A robustez é definida como a manutenção de acurácia sob ruído. v4 mantém 91,0% com $\sigma=0,3$ (perda de apenas 0,8 pp em relação à condição limpa), enquanto v1 cai a 77,8% (perda

de 2,2 pp). Esta diferença persiste em níveis maiores de ruído (Figura 3), indicando que o treinamento multi-sujeito balanceado produz superfícies de decisão com margem maior.




Figura 7. Degradação da acurácia top-1 sob ruído gaussiano aplicado às features normalizadas. Curvas mais planas indicam modelos mais robustos. v4 mantém vantagem estável sobre os demais em todos os níveis de ruído testados.

4.7 Sanitização por confiança

Avaliação do trade-off entre cobertura (fração de frames retidos) e acurácia (sobre os frames retidos) ao filtrar predições com confiança inferior a um limiar variável. Os modelos robustos, particularmente v4, permitem atingir acurácias próximas de 100% mantendo cobertura superior a 70%, característica relevante para aplicações em saúde onde a abstenção é preferível ao erro.




Figura 8. Sanitização por confiança. (Esquerda) acurácia em função do limiar de confiança mínima. (Direita) trade-off entre cobertura e acurácia. v4 oferece a melhor fronteira de Pareto.

5 DISCUSSÃO

5.1 Revisão das hipóteses do TCC I

A validação experimental motiva revisões fundamentadas em duas das três hipóteses secundárias formuladas no TCC I:

H1 (208 features biomecânicas): revisada para **120 atributos invariantes**. As 42 posições absolutas e 20 componentes de movimento dos 208 originais são sensíveis a posição da mão no

frame, escala e taxa de quadros — quantidades que variam entre datasets e câmaras. As 120 features mantidas (distâncias, ângulos, curvatura, orientação de palma) são matematicamente invariantes a translação, escala e rotação 2D, preservando a discriminação semântica e melhorando a generalização.

H2 (arquitetura CNN-LSTM): revisada para **DNN sobre frame único** no caso de letras estáticas. Atinge 91,8% de acurácia sem a complexidade adicional de modelagem temporal, que permanece relevante para sinais dinâmicos (palavras, frases) a ser avaliada em etapas futuras.

H3 (interface trilíngue): mantida; a integração da seleção de idioma de saída é independente do reconhecimento de sinais e será implementada na Etapa 5.

A **hipótese principal** (acurácia $\geq 80\%$) é confirmada com margem substancial: 91,81% em câmera real sobre sujeito não visto no treinamento.

5.2 Balanceamento multi-sujeito como recomendação prática

Os experimentos iterativos ($v1 \rightarrow v2 \rightarrow v3 \rightarrow v4$) demonstram que, neste pipeline e nesta tarefa, adições parciais e seletivas de dados multi-sujeito desestabilizam o classificador: cada iteração deslocou as fronteiras de decisão e degradou classes semanticamente vizinhas, com a instabilidade migrando entre iterações (U colapsou em v2; V e classes vizinhas em v3). Esta dinâmica é consistente com fenômenos amplamente documentados na literatura geral de aprendizagem de máquina: a teoria de desbalanceamento de classes descreve como a representação diferencial entre classes afeta a fronteira aprendida (He e Garcia, 2009; Krawczyk, 2016); a literatura de aprendizagem incremental e contínua caracteriza o esquecimento catastrófico que ocorre quando o modelo é exposto sequencialmente a subconjuntos de classes (Kirkpatrick et al., 2017; Parisi et al., 2019); a teoria de adaptação de domínio fundamenta matematicamente o efeito de distribuições de treino desbalanceadas sobre o desempenho em distribuições alvo (Ben-David et al., 2010).

A contribuição empírica deste trabalho não é, portanto, a descoberta do fenômeno em si, mas sua **demonstração quantitativa no contexto específico de reconhecimento de alfabeto LIBRAS via landmarks de mão**, com magnitudes concretas (oscilações entre +89,7 pp e -89,7 pp em letras individuais, segundo o subconjunto adicionado ao treinamento). A implicação prática para a Etapa 3 do cronograma (coleta de dados primários da LSP) é direta: priorizar coberturas **completas e balanceadas** do vocabulário-alvo por sujeito recrutado, evitando coletas focadas em sinais identificados como difíceis em pilotos parciais — preferência justificada empiricamente e alinhada à teoria pré-existente sobre desbalanceamento de classes.

5.3 Limitações

As limitações principais deste estudo são: (i) apenas 2 sujeitos humanos no protocolo de validação inter-sujeito — embora os resultados sejam consistentes, replicação com 5–10 sujeitos é necessária para reportar variância estatística; (ii) avaliação limitada a letras estáticas — sinais dinâmicos (palavras, frases) requerem modelagem temporal e provavelmente apresentam padrões distintos de overfitting; (iii) ausência de validação por intérprete certificado da gestualidade dos sujeitos — assume-se execução correta dos signos sem ground-truth externo; (iv) o sujeito S02 declarou condições distintas entre a sessão principal e a sessão S02-cluster (mão dominante L vs. R, iluminação, distância), o que pode ter introduzido variabilidade adicional não controlada.

6 CONCLUSÃO E TRABALHOS FUTUROS

Este trabalho documenta a validação técnica experimental do pipeline proposto no TCC I do projeto Ñemongueta, atingindo **91,81% de acurácia top-1 em câmera real** sobre sujeito não visto no treinamento — superando significativamente a meta de 80% estabelecida nas hipóteses do projeto. As contribuições específicas são: (i) pipeline de extração de 120 features biomecânicas

invariantes; (ii) protocolo padronizado de avaliação em câmera real com artefatos reusáveis; (iii) demonstração empírica, com magnitudes quantitativas, da instabilidade induzida por coletas multi-sujeito parciais no domínio de alfabeto LIBRAS — fenômeno que ilustra, no caso específico de reconhecimento via *landmarks* de mão, dinâmicas conhecidas em literaturas de desbalanceamento de classes, esquecimento catastrófico e adaptação de domínio.

Trabalhos futuros incluem: (i) coleta de dataset primário da LSP seguindo a recomendação prática derivada destes experimentos (cobertura balanceada por sujeito), com 3–5 sujeitos cobrindo o vocabulário-alvo completo; (ii) extensão do pipeline para sinais dinâmicos com arquitetura temporal (LSTM ou Transformer) e revalidação da invariância das features; (iii) implementação da camada de saída trilingue (espanhol paraguaio, guarani, português brasileiro) configurável pelo usuário; (iv) implantação como API REST (FastAPI) com latência ≤ 100 ms para aplicações em atendimento médico de emergência na região fronteiriça.

AGRADECIMENTOS

Ao orientador Prof. Willian Bogler da Silva pela condução metodológica do projeto, ao Centro Universitário União das Américas (UniAmérica) pela infraestrutura de pesquisa, e à comunidade surda da tríplice fronteira Ciudad del Este — Foz do Iguaçu — Puerto Iguazú pelas conversas que fundamentam a relevância social deste trabalho.

REFERÊNCIAS

- AHMED, S. et al. DeepSign: Sign Language Detection and Recognition Using Deep Learning. *Electronics*, v. 11, n. 11, p. 1780, 2022. DOI: 10.3390/electronics11111780.
- BEN-DAVID, S. et al. A theory of learning from different domains. *Machine Learning*, v. 79, n. 1-2, p. 151-175, 2010. DOI: 10.1007/s10994-009-5152-4.
- CAMGOZ, N. C. et al. Sign Language Transformers: Joint End-to-end Sign Language Recognition and Translation. In: IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2020.
- GAMARRA ROJAS, G. A. *Ñemongueta: Sistema de Reconhecimento Automático da Língua de Sinais Paraguaia com Suporte Trilingue Espanhol-Guarani-Português por emprego de Machine Learning*. TCC I, Centro Universitário União das Américas, Foz do Iguaçu, mar. 2026.
- GUTIERREZ, B. et al. Paraguayan Sign Language Translation using Machine Learning. In: International Multi-Conference on Complexity, Informatics and Cybernetics, 2024.
- HE, H.; GARCIA, E. A. Learning from Imbalanced Data. *IEEE Transactions on Knowledge and Data Engineering*, v. 21, n. 9, p. 1263-1284, 2009. DOI: 10.1109/TKDE.2008.239.
- HOCHREITER, S.; SCHMIDHUBER, J. Long Short-Term Memory. *Neural Computation*, v. 9, n. 8, p. 1735-1780, 1997.
- IDREES, A. et al. Real-Time Norwegian Sign Language Recognition Using MediaPipe and LSTM. *Multimodal Technologies and Interaction*, v. 9, n. 3, p. 23, 2025. DOI: 10.3390/mti9030023.
- KINGMA, D. P.; BA, J. Adam: A Method for Stochastic Optimization. arXiv:1412.6980, 2014.
- KIRKPATRICK, J. et al. Overcoming catastrophic forgetting in neural networks. *Proceedings of the National Academy of Sciences*, v. 114, n. 13, p. 3521-3526, 2017. DOI: 10.1073/pnas.1611835114.
- KOLLER, O. et al. Weakly Supervised Learning with Multi-stream CNN-LSTM-HMMs to Discover Sequential Parallelism in Sign Language Videos. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, v. 42, n. 9, p. 2306-2320, 2020.
- KRAWCZYK, B. Learning from imbalanced data: open challenges and future directions. *Progress in Artificial Intelligence*, v. 5, n. 4, p. 221-232, 2016. DOI: 10.1007/s13748-016-0094-0.
- PARISI, G. I. et al. Continual lifelong learning with neural networks: A review. *Neural Networks*, v. 113, p. 54-71, 2019. DOI: 10.1016/j.neunet.2019.01.012.
- PORFÍRIO, A.; WIGGERS, K.; OLIVEIRA, L. E. S.; WEINGAERTNER, D. LIBRAS sign language hand configuration recognition based on 3D meshes. In: IEEE International Conference on Systems, Man and Cybernetics (SMC), 2013.
- RODRIGUES, A.; ZANCHETTIN, C. V-Librasil: a new dataset with signs in Brazilian Sign Language. *IEEE DataPort*, 2024. DOI: 10.21227/v589-hn68.

SALEH, S.; ALNASSER, A. Deep Learning in Sign Language Recognition: A Hybrid Approach for the Recognition of Static and Dynamic Signs. *Mathematics*, v. 11, n. 17, p. 3729, 2023. DOI: 10.3390/math11173729.

ZHANG, F. et al. *MediaPipe Hands: On-device Real-time Hand Tracking*. arXiv:2006.10214, 2020.